# MAPSI — cours 1 : Rappels de probabilités et statistiques

Vincent Guigue

LIP6 - Université Paris 6, France

- Fonctionnement de l'UE MAPSI
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- Description d'une population, d'un échantillon
- Variables multiples, loi jointe, conditionnelle
- Indépendance probabiliste
- 6 Conclusion

### Buts de l'UE

- Fonctionnement de l'UE
- Rappels sur les base des probabilités et statistiques
- Modélisation de situations réelles
   & applications concrètes : classification automatique, régression...
  - ... dans différents domaines : textes, images...

## Règles de notation

### Organisation:

- Cours : théorie & concepts, exemples
- TD : applications & calculs sur feuille
- TME : mise en oeuvre des méthodes sur des exemples concrets

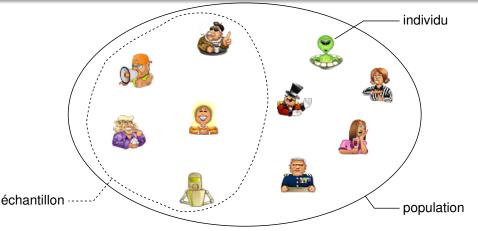
#### **Notation:**

- Examen final: 50%
- Partiel: 35%
- Notes de participation : 15%
  - Attention : l'essentiel de la note est constitué du travail effectué durant la séance
  - Soumission obligatoire du code de TME en fin de séance...
  - ... Et commentaires bienvenus pour faciliter la correction

- Groupe 1
  - Les TD ont lieu le lundi 8h30-10h30 en salle 14-24 105
  - Les TME ont lieu le lundi 10h45-12h45 en salle 24-25 302
- Groupe 2
  - Les TD ont lieu le mardi de 8h30-10h30 en salle 14-24 105
  - Les TME ont lieu le mardi 10h45-12h45 en salle 14-15 303
- Groupe 3 BIM-BMC
  - Les TD ont lieu le mardi de 8h30-10h30 en salle 23-24 202
  - Les TME ont lieu le mardi 13h45-15h45 en salle 14-15 307
- Groupe 4
  - Les TD ont lieu le mardi 8h30-10h30 en salle 23-24 205
  - Les TME ont lieu le mardi 10h45-12h45 en salle 14-15 406
- Groupe 5
  - Les TD ont lieu le jeudi 16h00-18h00 en salle???
  - les TME ont lieu le mardi 18h00-20h00 en salle 14-15-301

- Fonctionnement de l'UE MAPS
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- Description d'une population, d'un échantillon
- Variables multiples, loi jointe, conditionnelle
- Indépendance probabiliste
- 6 Conclusion

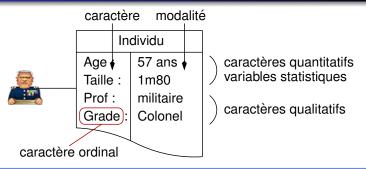
# Vocabulaire (1/3)



### Définitions

- population (statistique): ensemble des objets (ou personnes) sur lesquels porte l'étude
- o individu: chaque élément de la population

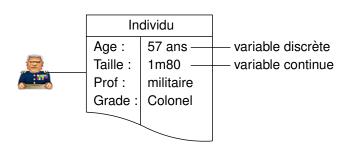
## Vocabulaire (2/3)



#### **Définitions**

- Caractères : critères d'étude de la population
- Modalités : les valeurs que peuvent prendre les caractères
- Caractère quantitatif ou Variable statistique : ensemble de modalités = des nombres + échelle mathématique
- Caractère qualitatif ou Variable catégorielle : caractère non quantitatif
- Caractère ordinal : les modalités sont ordonnées

## Vocabulaire (3/3)



### Définitions sur les variables statistiques

- Variable discrète : définie sur un espace discret (par exemple des entiers)
- Variable continue : définie sur un continuum (toutes les valeurs numériques d'un intervalle)

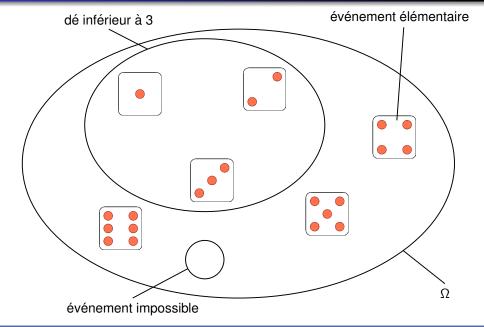
## Effectifs, fréquences et distributions

### Quelques définitions de statistiques

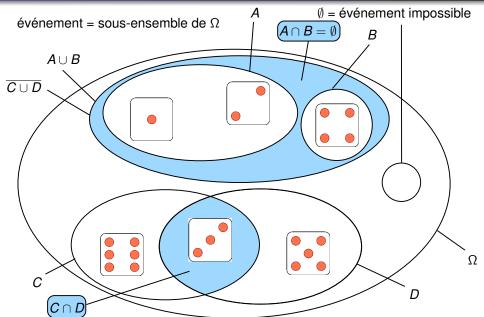
- X : caractère défini sur une population de N individus
- $\{x_1, \ldots, x_l\}$  modalités de X
- $N_i = \text{effectif de } x_i$ = nombre d'individus pour lesquels X a pris la valeur  $x_i$
- fréquence ou effectif relatif :  $f_i = \frac{N_i}{N}$
- distribution de X: ensemble des couples  $\{(x_1, f_1), (x_2, f_2), \ldots\}$ Représentation usuelle sous forme de tableau

Statistiques = description d'un échantillon Probabilités = description d'une population.

# Probabilités : approche évènementielle



# Les événements : des ensembles (1/2)



## Les événements : des ensembles (2/2)

#### Notations ensemblistes:

- événements = sous-ensembles de  $\Omega$
- Ø = événement impossible
- $A \cup B =$  événement qui est réalisé si A ou B est réalisé
- $C \cap D$  = événement qui est réalisé si C et D sont réalisés
- $\overline{C \cup D}$  = complémentaire de  $C \cup D$  dans  $\Omega$ 
  - = événement qui est réalisé ssi  $C \cup D$  ne l'est pas
- $A \cap B = \emptyset$  = 2 événements qui ne peuvent se réaliser simultanément

## Définition des probabilités : le cas discret

### Définition des probabilités (Kolmogorov)

- Ω = ensemble fini ou dénombrable d'événements élémentaires e<sub>k</sub>, k ∈ K ⊆ N
- $A = 2^{|\Omega|}$  = ensemble des événements
- Mesure de probabilité :  $\forall A \in \mathcal{A}, \ 0 \leq P(A) \leq 1$
- $P(\Omega) = 1$
- $A = \bigcup_{k \in L} A_k$ , avec L ensemble dénombrable et,  $\forall j, k \in L, j \neq k, A_j \cap A_k = \emptyset$ ,  $P(A) = \sum_{k \in L} P(A_k)$ .
- ⇒ Les probabilités des événements élémentaires déterminent entièrement *P*

conséquence : 
$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

## Univers, Evènements et Variable Aléatoire (1/5)

### Quelques définitions de probabilités

- Univers  $\Omega$ : un ensemble dénombrable (fini ou infini)
- Evènement : un sous-ensemble de l'univers  $\Omega$
- Mesure de probabilité : une fonction qui associe à chaque évènement une valeur entre 0 et 1, la probabilité de Ω est 1, et la probabilité d'une union dénombrable d'évènements incompatibles (ensembles disjoints) est la somme de leurs probabilités.
- Espace probabilisé : un couple  $(\Omega, P)$  où P est une mesure de probabilité sur  $\Omega$
- Variable aléatoire ...

## Univers, Evènements et Variable Aléatoire (2/5)

#### Variable aléatoire

Lorsqu'on est face à une expérience aléatoire, on s'intéresse plus souvent à une *valeur* attribuée au résultat qu'au résultat lui-même.

### Exemples

- Lorsque l'on joue à un jeu de hasard on s'intéresse plus au gain que l'on peut obtenir qu'au résultat du jeu.
- Nombre de pannes dans un ensemble de systèmes plutôt que l'état exact des systèmes
- Solution : "traduire" l'univers en évènements "compréhensibles".
- $\Rightarrow$  variable aléatoire : application de l'univers  $\Omega$  vers un autre ensemble.

## Univers, Evènements et Variable Aléatoire (3/5)

### Exemple du lancer de dé

On lance un dé après avoir misé 1 *EUR*. Si le résultat est un 5 ou un 6 on double la mise, sinon perd la mise. Dans ce cas :

- $\Omega = \{1, 2, 3, 4, 5, 6\}$
- Card  $\Omega=6$ , Card  $\mathcal{P}(\Omega)=2^6$ , et  $\forall e\in\Omega, P(e)=\frac{1}{6}$
- Soit X la v.a. qui associe à tout résultat du dé un gain: X(1) = X(2) = X(3) = X(4) = -1 et X(5) = X(6) = (2-1) = 1 X est à valeur dans l'ensemble noté  $\mathcal{X} = \{-1, 1\} \subset \mathbb{R}$ ,  $X: \Omega \to \mathcal{X}$
- Question :
   Comment calculer la probabilité de gagner 1 EUR ?
- Réponse : Définir une probabilité sur  $\mathcal{X}$ , notée  $\mathbb{P}$ , en retournant dans l'espace probabilisé  $(\Omega, \mathcal{P}(\Omega), P)$  i.e. utiliser P(résultat du dé = 5 ou 6) pour estimer  $\mathbb{P}(\{1\})$ .

## Variable aléatoire à valeurs discrètes (4/5)

#### Définition Variable aléatoire à valeurs discrètes

Soit  $\Omega$  un ensemble dénombrable, et P une mesure de probabilité sur  $\Omega$ .

Soit  $\Omega'$ , un ensemble discret. Une variable aléatoire est une fonction X de  $\Omega$  muni de la mesure P vers  $\Omega'$ .

### Exemples

- Lancer d'un dé :
  - Soit  $\Omega = \{1, ..., 6\}$  muni de la probabilité uniforme P.
  - $X: i \mapsto \begin{cases} 1 \text{ si } i \text{ est pair} \\ 0 \text{ sinon} \end{cases}$
  - est une variable aléatoire de  $(\Omega, P)$  vers  $\Omega' = \{0, 1\}$ .
- Lancer de deux dés : Soit  $\Omega = \{1, ..., 6\}^2$  muni de la probabilité uniforme P.

$$X:(i,j)\mapsto i+j$$

est une variable aléatoire de  $(\Omega, P)$  vers  $\Omega' = \{2, ..., 12\}$ 

# Variable aléatoire à valeurs discrètes (5/5)

### Définitions : Loi de probabilité

Soit  $(\Omega, P)$  un espace probabilisé où  $\Omega$  est dénombrable. Soit  $\Omega'$  un ensemble discret, et X une v.a. de  $(\Omega, P)$  vers  $\Omega'$ .

•  $P_X$  définit une mesure de probabilité sur  $\Omega'$ :

$$\forall E' \subset \Omega', \quad P_X(E') = P(X^{-1}(E'))$$

avec 
$$X^{-1}(E') = \{\omega \in \Omega | X(\omega) \in E'\}$$

• L'ensemble des valeurs  $P_Xig(\{\omega'\}ig)$  pour  $\omega'\in\Omega'$  s'appelle la loi de probabilité de X.

#### **Notations**

- L'événement  $X \in ]-\infty, a]$  sera noté par  $X \leq a$
- L'événement  $X \in ]a, b]$  sera noté par  $a < X \le b$
- L'événement  $X \in \{a\}$  sera noté par X = a
- On a donc  $P_X(B) = P(X^{-1}(B)) = P(X \in B)$

- Fonctionnement de l'UE MAPS
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- 3 Description d'une population, d'un échantillon
- Variables multiples, loi jointe, conditionnelle
- Indépendance probabiliste
- 6 Conclusion

#### DESCRIPTION D'UNE POPULATION

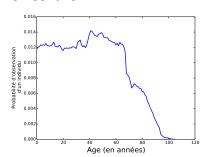
- A partir d'un échantillon
- En simplifiant les données continues
- ...

## Description d'une population

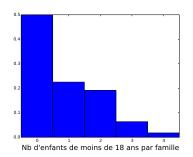
Décrire parfaitement une population = connaître sa loi de probabilité

Exemples selon la nature des variables :

#### en continu:



### en discret :



## Description d'une population

Décrire parfaitement une population = connaître sa loi de probabilité

### Problème général:

Comment déduire la loi sur la population si on ne connait qu'un échantillon?

Réponse dans les cours suivants...

## Propriétés

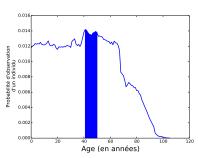
#### Cas général :

- Une distribution somme à 1
- Une probabilité est toujours ≥ 0

#### Cas Continu:

- Chaque événement élémentaire a une proba = 0 (eg : proba d'avoir 40 ans)
- Mais proba d'être dans un intervalle ≥ 0 (eg : proba d'avoir entre 40 et 50 ans)

P(A) = surface délimitée par la **fonction de densité** dans la zone où les événements sont inclus dans A



### Probabilités : les détails dans le cas continu



$$P(X \in I) = \int_{I} p(x) dx$$

avec P = proba et p = fonction de densité

 $\implies$  connaître p = connaître P

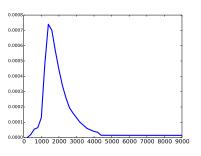
intervalles  $]-\infty,x[\Longrightarrow$  fonction de répartition :

$$F(x) = P(X < x) = \int_{-\infty}^{x} p(y) dy$$

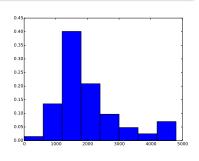
### Discrétisation

Continu → Discret

Possibilité de discrétisation = regroupement par tranches Modélisation approximative, mais manipulation plus facile



Distribution des salaires en France



Distribution des salaires en France discrétisée

# Caractéristiques d'une loi de probabilités (1/2)

### Caractéristiques

Espérance mathématique ou moyenne : E(X)

$$X$$
 discrète :  $E(X) = \sum x_k p_k$ 

$$X$$
 continue :  $E(X) = \int x p(x) dx$ 

- l'espérance mathématique n'existe pas toujours
- Mode : Mo de P (pas toujours unique) :
  - X discrète :  $p(Mo) = \max_k p(x_k)$
  - X continue :  $p(Mo) = \max_{x} p(x)$

### Propriétés de l'espérance

- E(aX + b) = aE(X) + b

# Caractéristiques d'une loi de probabilités (2/2)

- variance : V(X) ou  $\sigma^2$  :
  - *X* discrète :  $\sigma^2 = \sum [x_k E(X)]^2 p_k$

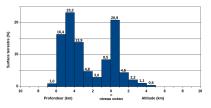
X continue : 
$$\sigma^2 = \int [x - E(X)]^2 p(x) dx$$

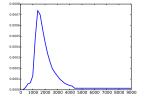
- moyenne des carrés des écarts entre les valeurs prises par X et son espérance E(X)
- écart-type :  $\sigma$  = racine carrée de la variance
- variance et donc écart-type n'existent pas toujours
- **Prop**: Y = aX + b, où a et b sont des nombres réels  $V(Y) = a^2V(X)$
- Prop :  $V(X) = E[X^2] E[X]^2$

# Résumer les informations prépondérantes

#### Idées:

- Caractériser rapidement une distribution
- 2 Donner en quelques chiffres une idée approchée de l'ensemble de la distribution de probabilité.
- Espérance, variance + moments statistiques





Niveau du sol sur la planète

Quantiles (médianes, ...)

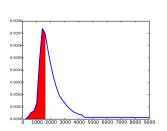
Médiane = 1650, Moyenne = 1950

## Médiane d'une variable statistique continue

### Médiane d'une variable statistique continue

- X : variable statistique continue
- Médiane = le nombre  $\delta$  tel que les aires situées de part et d'autre de ce nombre dans l'histogramme représentant X sont égales

Médiane  $M: P(X \leq M) \geq \frac{1}{2}$  et  $P(X \geq M) \geq \frac{1}{2}$ 



#### World Median Ages



YOUNGEST: 1. Niger (15.1) 2. Uganda (15.5) 3. Mali (16) 4. Malawi (16.3) 5. Zambia (16.7) OLDEST: 1. Germany & Japan (46.1) 2.Italy (44.5) 3. Austria (44.3) 4. Virgin Islands (44.2)

## Les quantiles

### Quantile d'une variable discrète

- X: variable statistique discrète, modalités  $\{x_1, \ldots, x_l\}$
- population de N individus
- quantile d'ordre  $\alpha = \delta$  tel que :

$$\#\{j: x_j < \delta\} \le \alpha N$$
 et  $\#\{j: x_j > \delta\} \le (1 - \alpha)N$ 

#### Quantile d'une variable continue

- X : variable statistique continue
- quantile d'ordre  $\alpha$  = le nombre  $\delta$  tel que les aires situées de part et d'autre de ce nombre dans l'histogramme représentant X sont égales respectivement à  $\alpha \times$  aire totale et  $(1-\alpha) \times$  aire totale

- Fonctionnement de l'UE MAPS
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- 3 Description d'une population, d'un échantillon
- Variables multiples, loi jointe, conditionnelle
- Indépendance probabiliste
- 6 Conclusion

## Loi de probabilité sur plusieurs variables aléatoires

 Chaque individu de la population est décrit sur plusieurs caractères

#### Exemples:

- Carte à jouer : Couleur (Trefle, Carreau, Coeur, Pique),
   Valeur (7, ..., Roi)
- $\bullet$  Sportifs : Age (< 20, ..., > 50), Sport pratiqué (Natation...)

Loi jointe P(A, B): décrire toutes les intersections possibles Exemple:

Sport \ Age	< 20	[20, 30[	[30, 40[,	[40, 50[	≥ <b>50</b>
Natation	0.02	0.05	0.09	0.08	0.08
Jogging	0.10	0.15	0.10	0.07	0.05
Tennis	0.02	0.03	0.06	0.07	0.03

NB : l'ensemble de l'univers  $\Omega$  somme toujours à 1

## Loi marginale

#### Définition

La marginalisation consiste à projeter une loi jointe sur l'une des variables aléatoires.

Par exemple, extraire P(A) à partir de P(A, B).

$$P(A) = \sum_{i} P(A, B = b_i)$$

Sport \ Age	< 20	[20, 30[	[30, 40[,	[40, 50[	≥ <b>50</b>	Marginale
Natation	0.02	0.05	0.09	0.08	0.08	0.32
Jogging	0.10	0.15	0.10	0.07	0.05	0.47
Tennis	0.02	0.03	0.06	0.07	0.03	0.21
						1

La marginale extraite ici correspond à P(Sport). La nouvelle loi somme toujours à 1.

## Loi marginale

#### Définition

La marginalisation consiste à projeter une loi jointe sur l'une des variables aléatoires.

Par exemple, extraire P(A) à partir de P(A, B).

$$P(A) = \sum_{i} P(A, B = b_i)$$

Sport \ Age	< 20	[20, 30[	[30, 40[,	[40, 50[	≥ <b>50</b>
Natation	0.02	0.05	0.09	0.08	0.08
Jogging	0.10	0.15	0.10	0.07	0.05
Tennis	0.02	0.03	0.06	0.07	0.03
Marginale	0.14	0.23	0.25	0.22	0.16

## Probabilités conditionnelles (1/5)

### Définition

la probabilité d'un événement A conditionnellement à un événement B, que l'on note P(A|B), est la probabilité que A se produise sachant que B s'est ou va se produire.

Rem :  $P(A|\Omega) = P(A)$  puisqu'on sait que  $\Omega$  sera réalisé

Problème : comment calculer P(A|B) ?

## Probabilités conditionnelles (2/5)

#### Exemple

- Tirer une carte parmi un jeu de 32 cartes
- $\Omega = \{32 \text{ cartes}\}$
- événements : A = tirer un roi B = tirer un cœur
- P(A|B) = ?

#### Interprétation de P(A|B)

Dans l'univers réduit B ( $\Omega' = B$ ), quelle est la probabilité de A?

# Probabilités conditionnelles (2/5)

#### Exemple

- Tirer une carte parmi un jeu de 32 cartes
- $\Omega = \{32 \text{ cartes}\}$
- événements : A = tirer un roi B = tirer un cœur
- P(A|B) = ?

#### Interprétation de P(A|B)

Dans l'univers réduit B ( $\Omega' = B$ ), quelle est la probabilité de A?

- $\Omega' = B = coeur$  (8 cartes)
- P(A|B) = un roi parmi les coeur...

# Probabilités conditionnelles (2/5)

#### Exemple

- Tirer une carte parmi un jeu de 32 cartes
- $\Omega = \{32 \text{ cartes}\}$
- événements : A = tirer un roi B = tirer un cœur
- P(A|B) = ?

#### Interprétation de P(A|B)

Dans l'univers réduit B ( $\Omega' = B$ ), quelle est la probabilité de A?

- $\Omega' = B = coeur$  (8 cartes)
- P(A|B) = un roi parmi les coeur...

$$P(A|B) = \frac{1}{8}$$

## Probabilités conditionnelles (3/5)

#### Théorème des probabilités totales :

En partant de la loi jointe

$$P(A|B) = \frac{P(A,B)}{P(B)}$$
 ou  $P(A,B) = P(A|B)P(B)$ 

**Interprétation**: l'observation conjointe de A et B (P(A, B)) correspond à l'observation de B ET à l'observation de A dans l'univers restreint B.

### Probabilités conditionnelles (3/5)

#### Théorème des probabilités totales :

En partant de la loi jointe

$$P(A|B) = \frac{P(A,B)}{P(B)}$$
 ou  $P(A,B) = P(A|B)P(B)$ 

**Interprétation**: l'observation conjointe de A et B (P(A, B)) correspond à l'observation de B ET à l'observation de A dans l'univers restreint B.

**Exemple:** Roi de coeur = Observer un coeur ET observer un roi dans l'univers des coeurs

## Probabilités conditionnelles (4/5)

#### **Propriétés**

- Réversible : P(A, B) = P(A|B)P(B) = P(B|A)P(A)
- Théorème de Bayes :

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Intégration des probabilités totales :

$$P(A) = \sum_{i} P(A, B = b_i) = \sum_{i} P(A|B = b_i)P(B_i)$$

### Probabilités conditionnelles (5/5)

Tableau de probabilité conditionnelle :

	Natation	0.32
Sport : $P(A) = \frac{1}{2}$	Jogging	0.47
	Tennis	0.21

Répartition des ages pour chaque sport :

- Propriété : chaque ligne somme à 1 (=chaque ligne est un univers à part)
- Questions : comment extraire la distribution des ages ? Comment obtenir la distribution jointe ?

## Caractéristiques d'une loi de probabilités

#### Propriétés de la variance

- $\forall X, Y, V(X + Y) = V(X) + V(Y) + 2cov(X, Y) où :$ 
  - cov(X, Y) = covariance de X et Y
  - si X et Y discrètes et  $p_k = P(X = x_k, Y = y_k)$

$$cov(X, Y) = \sum [x_k - E(X)][y_k - E(Y)]\rho_k$$

• si X et Y continues, de densité p(x, y),

$$cov(X, Y) = \iint [x - E(X)][y - E(Y)]p(x, y)dxdy$$

- Fonctionnement de l'UE MAPS
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- Description d'une population, d'un échantillon
- Variables multiples, loi jointe, conditionnelle
- 5 Indépendance probabiliste
- 6 Conclusion

### Indépendance probabiliste (1/3)

#### Définition de l'indépendance

deux événements A et B sont indépendants si :

$$P(A, B) = P(A) \times P(B)$$

Corrolaire : deux événements A et B sont indépendants si : P(A|B) = P(A) (avec P(B) > 0)

l'indépendance n'est pas une propriété du couple (A, B) mais du couple  $(\{A, A^c\}, \{B, B^c\})$ :

A et B sont indépendants  $\Longrightarrow$  A et  $B^c$  indépendants  $\Longrightarrow$   $A^c$  et B indépendants  $\Longrightarrow$   $A^c$  et  $B^c$  indépendants

## Indépendance probabiliste (2/3)

#### Démonstration :

A et B sont indépendants 
$$\Longrightarrow P(A,B) = P(A) \times P(B)$$

$$P(A) = P(A,B) + P(A,B^c)$$

$$\Longrightarrow P(A,B^c) = P(A) - P(A,B)$$

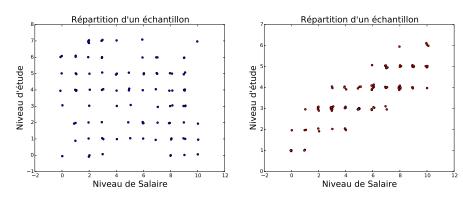
$$= P(A) - P(A) \times P(B)$$

$$= P(A) \times [1 - P(B)]$$

$$= P(A) \times P(B^c)$$

# Indépendance probabiliste (3/3)

#### **Exemple**



Qu'est ce qui est dépendant ou indépendant?

## Indépendance (exemple)

Indépendance ou pas entre X et Y?

#### Cas 1:

	<i>y</i> <sub>1</sub>	<i>y</i> <sub>2</sub>
<i>X</i> <sub>1</sub>	0.04	0.06
<i>X</i> <sub>2</sub>	0.36	0.54

#### Cas 3:

	<i>y</i> <sub>1</sub>	<i>y</i> <sub>2</sub>	<i>y</i> <sub>3</sub>
<i>X</i> <sub>1</sub>	0.07	0.24	0.16
X <sub>2</sub>	0.07	0.30	0.16

#### Cas 2:

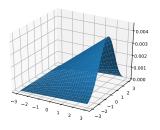
	<i>y</i> <sub>1</sub>	<b>y</b> <sub>2</sub>
<i>X</i> <sub>1</sub>	0.1	0.2
<i>X</i> <sub>2</sub>	0.3	0.4

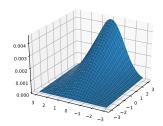
#### Cas 4:

	<i>y</i> <sub>1</sub>	<i>y</i> <sub>2</sub>	<b>y</b> 3
<i>X</i> <sub>1</sub>	0.01	0.02	0.06
<i>X</i> <sub>2</sub>	0.09	0.18	0.54

## Indépendance (exemple graphique)

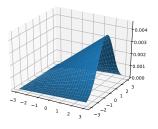
### Représentation d'une loi jointe $P(X_1, X_2)$

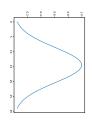


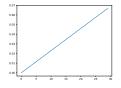


## Indépendance (exemple graphique)

#### Représentation d'une loi jointe $P(X_1, X_2)$

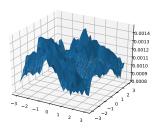


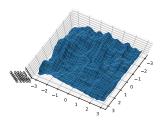




### Indépendance (exemple graphique)

### Représentation d'une loi jointe $P(X_1, X_2)$





- Combien de variable pour modéliser la probabilité de voir son toit s'envoler?
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)
- Combien de variable pour modéliser les probabilités de tirage de 3 dés (cumul)?

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)
- Combien de variable pour modéliser les probabilités de tirage de 3 dés (cumul)?
  - Indépendance ! Dés identiques = 6 valeurs
  - Dés différents =  $3 \times 6 = 18$  valeurs
  - Dés non indépendants (?)  $6 \times 6 \times 6 = 216$  valeurs

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)
- Combien de variable pour modéliser les probabilités de tirage de 3 dés (cumul)?
  - Indépendance! Dés identiques = 6 valeurs
  - Dés différents =  $3 \times 6 = 18$  valeurs
  - Dés non indépendants (?)  $6 \times 6 \times 6 = 216$  valeurs
- Combien de variables pour modéliser les probabilités d'apparition de groupes de 3 mots (tri-grammes) ?
   -Vocabulaire réduit à 10k mots-

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)
- Combien de variable pour modéliser les probabilités de tirage de 3 dés (cumul)?
  - Indépendance! Dés identiques = 6 valeurs
  - Dés différents =  $3 \times 6 = 18$  valeurs
  - Dés non indépendants (?)  $6 \times 6 \times 6 = 216$  valeurs
- Combien de variables pour modéliser les probabilités d'apparition de groupes de 3 mots (tri-grammes)?
  - -Vocabulaire réduit à 10k mots-
    - $10k^3 = 10^{12}$  valeurs (=4000 Go)

### Quantifier la dépendance entre X et Y

#### Définition : Coefficient de corrélation linéaire

Soit X, Y deux variables. Le coefficient de corrélation linéaire entre X et Y est :

$$r = \frac{\mathsf{cov}\left(X,\,Y\right)}{\sigma_X \sigma_Y},$$

où  $\sigma_X$  et  $\sigma_Y$  sont les écart-types des variables X et Y.

- Fonctionnement de l'UE MAPS
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- Description d'une population, d'un échantillon
- Variables multiples, loi jointe, conditionnelle
- Indépendance probabiliste
- 6 Conclusion

#### Les 4 règles qui vont vous sauver la vie.

Probabilité :

$$\forall x \in \mathcal{X}, \quad 0 \le P(x) \le 1 \text{ et } \sum_{x \in \mathcal{X}} p(x) = 1$$

Marginalisation

$$P(X_1 = x_1) = \sum_{x_2,...,x_n} P(X_1 = x_1, X_2 = x_2,...)$$

Conditionalisation:

$$P(X_1, X_2) = P(X_1|X_2)P(X_2)$$
 (et vice versa)

• Indépendance : Si  $X_1$  et  $X_2$  sont indépendantes :  $P(X_1, X_2) = P(X_1)P(X_2)$