

# MAPSI — cours 10 : Regressions

Vincent Guigue, Christophe Gonzales  
`vincent.guigue@lip6.fr`

LIP6 – Université Paris 6, France

- Jusqu'ici, beaucoup de problèmes de **classification**
  - supervisés (chiffres, lettres)
  - non-supervisés (geyser)
- D'autres problèmes existent...
  - suivi de cibles (cf cours 9)
  - modélisation explicative (neurosciences)
  - **regression** : modèle expliquant une variable continue
- Sources de données
  - [www.kaggle.com](http://www.kaggle.com)
  - <http://archive.ics.uci.edu/ml/>
- Jouer avec les données... C'est un métier : data scientist.

## ● Prédiction des prix des maisons (Boston)

- |             |   |
|-------------|---|
| 1. CRIM     | per capita crime rate by town   |
| 2. ZN       | proportion of residential land zoned for lots over 25,000 sq.ft.      |
| 3. INDUS    | proportion of non-retail business acres per town                      |
| 4. CHAS     | Charles River dummy variable (= 1 if tract bounds river; 0 otherwise) |
| 5. NOX      | nitric oxides concentration (parts per 10 million)                    |
| 6. RM       | average number of rooms per dwelling                                  |
| 7. AGE      | proportion of owner-occupied units built prior to 1940                |
| 8. DIS      | weighted distances to five Boston employment centres                  |
| 9. RAD      | index of accessibility to radial highways                             |
| 10. TAX     | full-value property-tax rate per \$10,000                             |
| 11. PTRATIO | pupil-teacher ratio by town   |
| 12. B       | $1000(B_k - 0.63)^2$ where $B_k$ is the proportion of blacks by town  |
| 13. LSTAT   | % lower status of the population                                      |
| 14. MEDV    | Median value of owner-occupied homes in \$1000's                      |



- Prédiction des notes du vin
- Prédiction du prix des voitures d'occasion

# Regression : cas d'usage

- Prédiction des prix des maisons (Boston)
- Prédiction des notes du vin
  - 1) Alcohol
  - 2) Malic acid
  - 3) Ash
  - 4) Alcalinity of ash
  - 5) Magnesium
  - 6) Total phenols
  - 7) Flavanoids
  - 8) Nonflavanoid phenols
  - 9) Proanthocyanins
  - 10) Color intensity
  - 11) Hue
  - 12) OD280/OD315 of diluted wines
  - 13) Proline
- Prédiction du prix des voitures d'occasion



# Regression : cas d'usage

- Prédiction des prix des maisons (Boston)
- Prédiction des notes du vin
- Prédiction du prix des voitures d'occasion

1. symboling:	-3, -2, -1, 0, 1, 2, 3.
2. normalized-losses:	continuous from 65 to 256.
3. make:	alfa-romero, audi, bmw, chevrolet, dodge, honda, isuzu, jaguar, mazda, mercedes-benz, mercury, mitsubishi, nissan, peugot, plymouth, porsche, renault, saab, subaru, toyota, volkswagen, volvo diesel, gas.
4. fuel-type:	std, turbo.
5. aspiration:	four, two.
6. num-of-doors:	hardtop, wagon, sedan, hatchback, convertible.
7. body-style:	4wd, fwd, rwd.
8. drive-wheels:	front, rear.
9. engine-location:	continuous from 86.6 120.9.
10. wheel-base:	continuous from 141.1 to 208.1.
11. length:	continuous from 60.3 to 72.3.
12. width:	continuous from 47.8 to 59.8.
13. height:	continuous from 1488 to 4066.
14. curb-weight:	dohc, dohcvt, l, ohc, ohcf, ohcv, rotor.
15. engine-type:	eight, five, four, six, three, twelve, two.
16. num-of-cylinders:	continuous from 61 to 326.
17. engine-size:	1bbl, 2bbl, 4bbl, idi, mfi, mpfi, spdi, spfi.
18. fuel-system:	continuous from 2.54 to 3.94.
19. bore:	continuous from 2.07 to 4.17.
20. stroke:	continuous from 7 to 23.
21. compression-ratio:	continuous from 48 to 288.
22. horsepower:	continuous from 4150 to 6600.
23. peak-rpm:	continuous from 13 to 49.
24. city-mpg:	continuous from 16 to 54.
25. highway-mpg:	continuous from 5118 to 45400.
26. price:	



- Prédiction des prix des maisons (Boston)
- Prédiction des notes du vin
- Prédiction du prix des voitures d'occasion
- Résistance du béton
- Propagation des feux de forêt
- Consommation électrique
- Eruptions solaires
- ...

# Régression simple (1)

- $X$  et  $Y$  jouent des rôles dissymétriques
- $Y$  = variable expliquée = variable endogène
- on veut « expliquer » la valeur de  $Y$  par celle de  $X$

# Régression simple (1)

- $X$  et  $Y$  jouent des rôles dissymétriques
- $Y$  = variable expliquée = variable endogène
- on veut « expliquer » la valeur de  $Y$  par celle de  $X$



$X$  = taux d'alcool dans le sang  $\implies Y$  = vitesse



$X$  = surface du logement  $\implies Y$  = prix au  $m^2$



$X$  = quantité d'engrais à l'hectare  $\implies Y$  = rendement



Variable exogène  $X$  peut être aléatoire, mais pas forcément :



⇒ l'expérimentateur peut faire varier comme il veut la quantité d'engrais de parcelle en parcelle

Variable exogène  $X$  peut être aléatoire, mais pas forcément :



⇒ l'expérimentateur peut faire varier comme il veut la quantité d'engrais de parcelle en parcelle

### *Hypothèse*

- relation imprécise entre  $X$  et  $Y$
- valeur de  $Y$  dépend de  $X$  et d'un facteur aléatoire  $\mathcal{E}$  :  
 $Y = f(X, \mathcal{E})$
- $\mathcal{E}$  = résidu = erreur = bruit


$$Y = f(X, \mathcal{E})$$

- $\mathcal{E}$  variable aléatoire  $\implies Y$  variable aléatoire

### *Modèle linéaire ou régression*

- On dispose de  $n$  observations  $(x_i, y_i)$  du couple  $(X, Y)$
- fonction  $f$  affine :  $Y = \alpha + \beta X + \mathcal{E}$
- $\alpha$  et  $\beta$  = paramètres inconnus
- observations telles que :  $y_i = \alpha + \beta x_i + \mathcal{E}_i$
- existence des résidus  $\mathcal{E}_i$ 
  - $\implies$  les points  $(x_i, y_i)$  ne sont pas sur une même droite
  - $\implies$  on ne peut déterminer exactement  $\alpha$  et  $\beta$
  - $\implies$  estimation de  $\alpha$  et  $\beta$


## Régression simple (4)



$$Y = \alpha + \beta X + \epsilon$$

# Formalisation mono-dimensionnelle

- Cas simple : régression linéaire mono-dimensionnelle



Modélisation :  $Y = \alpha + \beta X + \mathcal{E}$

On dispose d'un ensemble d'observations  $(x_i, y_i)$

$\Rightarrow$  trouver  $\alpha^*, \beta^*$

# Formalisation mono-dimensionnelle (2)

- Modélisation :  $Y = \alpha + \beta X + \mathcal{E}$
- $\mathcal{E}$  est une variable aléatoire,  $\{\dots, \mathcal{E}_i, \dots\}$  sont des tirages selon cette loi
- Hypothèse (dite du bruit blanc) :  $\mathcal{E} \sim \mathcal{N}(0, \sigma)$
- Notations :
  - $Y_i = \alpha + \beta X_i + \mathcal{E}_i$  et :  $E[Y_i] = \alpha + \beta x_i$ ,  $V[Y_i] = \sigma^2$
  - On note  $Y_i \sim \mathcal{N}(\alpha + \beta x_i, \sigma)$

$$Y = \alpha + \beta X + \mathcal{E} \quad E(Y) = \alpha + \beta E(X)$$

$$Y = \alpha + \beta X + \varepsilon \quad E(Y) = \alpha + \beta E(X)$$

$$Y - E(Y) = \beta(X - E(X)) + \varepsilon$$



$$Y = \alpha + \beta X + \varepsilon \quad E(Y) = \alpha + \beta E(X)$$

$$Y - E(Y) = \beta(X - E(X)) + \varepsilon$$

Multiplication par  $(X - E(X))$  et passage à l'espérance :

$$E[(Y - E(Y))(X - E(X))] = \beta E[(X - E(X))^2] + E[\varepsilon(X - E(X))]$$

$$Y = \alpha + \beta X + \mathcal{E} \quad E(Y) = \alpha + \beta E(X)$$

$$Y - E(Y) = \beta(X - E(X)) + \mathcal{E}$$

Multiplication par  $(X - E(X))$  et passage à l'espérance :

$$E[(Y - E(Y))(X - E(X))] = \beta E[(X - E(X))^2] + E[\mathcal{E}(X - E(X))]$$

$$\text{cov}(X, Y) = \beta \sigma_X^2 + \text{cov}(\mathcal{E}, X) \quad \text{or : } \text{cov}(\mathcal{E}, X) = 0 \text{ par hypothèse (bruit)}$$

$$Y = \alpha + \beta X + \varepsilon \quad E(Y) = \alpha + \beta E(X)$$

$$Y - E(Y) = \beta(X - E(X)) + \varepsilon$$

Multiplication par  $(X - E(X))$  et passage à l'espérance :


$$E[(Y - E(Y))(X - E(X))] = \beta E[(X - E(X))^2] + E[\varepsilon(X - E(X))]$$

$\text{cov}(X, Y) = \beta \sigma_X^2 + \text{cov}(\varepsilon, X)$  or :  $\text{cov}(\varepsilon, X) = 0$  par hypothèse (bruit)

$$\beta^* = \frac{\text{cov}(X, Y)}{\sigma_X^2} \quad \alpha^* = E(Y) - \frac{\text{cov}(X, Y)}{\sigma_X^2} E(X)$$

# Conclusion


On peut trouver l'équation de la droite qui explique les points (avec des hypothèses sur  $\mathcal{E}$ )



$$\beta^* = \frac{\text{cov}(X, Y)}{\sigma_X^2} \quad \alpha^* = E(Y) - \frac{\text{cov}(X, Y)}{\sigma_X^2} E(X)$$



# Conclusion (2)

- Ca marche bien...




# Conclusion (2)

- Ca marche bien... sur des données linéaires



# Changement de variable



$$\ln Y = -1 + 0,5X^2$$

$\Rightarrow$  changement de variables :  $Y' = \ln Y$  et  $X' = X^2$

$$\Rightarrow Y' = -1 + 0,5X'$$

- On dispose toujours d'observations iid  $\{(x_i, y_i)\}_{i=1, \dots, N}$  et on fait toujours une hypothèse gaussienne sur le bruit
- Généralisation à n'importe quel modélisation  $Y = f(X)$ ,
- Par exemple :  $Y = \alpha X^2 + \beta X + \gamma + \mathcal{E}$
- Notations :
  - $Y_i \sim \mathcal{N}(\alpha x_i^2 + \beta x_i + \gamma, \sigma)$
  - Proba. d'observation :

$$p(y_i | x_i, \theta, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2} \|y_i - f(x_i)\|^2\right)$$



- On dispose toujours d'observations iid  $\{(x_i, y_i)\}_{i=1, \dots, N}$  et on fait toujours une hypothèse gaussienne sur le bruit
- Généralisation à n'importe quel modélisation  $Y = f(X)$ ,
- Par exemple :  $Y = \alpha X^2 + \beta X + \gamma + \mathcal{E}$
- Notations :
  - $Y_i \sim \mathcal{N}(\alpha x_i^2 + \beta x_i + \gamma, \sigma)$
  - Proba. d'observation :

$$p(y_i | x_i, \theta, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2} \|y_i - f(x_i)\|^2\right)$$

- Vraisemblance :

$$\mathcal{L} = p(\mathbf{y} | \mathbf{x}, \theta, \sigma) = \prod_i \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2} \|y_i - f(x_i)\|^2\right)$$

- Comment maximiser la vraisemblance ?

$$\mathcal{L} = p(\mathbf{y}|\mathbf{x}, \theta, \sigma) = \prod_i \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(y_i - f(x_i))^2\right)$$

- On fait souvent l'hypothèse que  $\sigma$  est connu
- Passage au log :

$$\log \mathcal{L} = \sum_i -\log(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2}(y_i - f(x_i))^2$$

## Approche standard :

- Calcul du gradient
- Annulation du gradient
  - Analytique (si possible)
  - Itérative (sinon)

Définition : gradient = vecteur des dérivées par rapport aux paramètres

- Simplification (si  $\sigma$  est connu), et  $f(x) = \alpha x^2 - \beta x - \gamma$

$$\arg \max_{\alpha, \beta, \gamma} \sum_i -\log(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} (y_i - f(x_i))^2 = \arg \max_{\alpha, \beta, \gamma} \sum_i -(y_i - f(x_i))^2$$

- Calcul du gradient ( $\nabla$ ) :

- Simplification (si  $\sigma$  est connu), et  $f(x) = \alpha x^2 - \beta x - \gamma$

$$\arg \max_{\alpha, \beta, \gamma} \sum_i -\log(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} (y_i - f(x_i))^2 = \arg \max_{\alpha, \beta, \gamma} \sum_i -(y_i - f(x_i))^2$$

- Calcul du gradient ( $\nabla$ ) :

$$\nabla_{\alpha, \beta, \gamma} \mathcal{L}_{red} = \begin{bmatrix} \frac{\partial(\sum_i -(y_i - f(x_i))^2)}{\partial \alpha} \\ \frac{\partial(\sum_i -(y_i - f(x_i))^2)}{\partial \beta} \\ \frac{\partial(\sum_i -(y_i - f(x_i))^2)}{\partial \gamma} \end{bmatrix} = \begin{bmatrix} \sum_i 2x_i^2 (y_i - \alpha x_i^2 - \beta x_i - \gamma) \\ \sum_i 2x_i (y_i - \alpha x_i^2 - \beta x_i - \gamma) \\ \sum_i 2 (y_i - \alpha x_i^2 - \beta x_i - \gamma) \end{bmatrix}$$

- Simplification (si  $\sigma$  est connu), et  $f(x) = \alpha x^2 - \beta x - \gamma$

$$\arg \max_{\alpha, \beta, \gamma} \sum_i -\log(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} (y_i - f(x_i))^2 = \arg \max_{\alpha, \beta, \gamma} \sum_i -(y_i - f(x_i))^2$$

- Calcul du gradient ( $\nabla$ ) :

$$\nabla_{\alpha, \beta, \gamma} \mathcal{L}_{red} = \begin{bmatrix} \frac{\partial(\sum_i -(y_i - f(x_i))^2)}{\partial \alpha} \\ \frac{\partial(\sum_i -(y_i - f(x_i))^2)}{\partial \beta} \\ \frac{\partial(\sum_i -(y_i - f(x_i))^2)}{\partial \gamma} \end{bmatrix} = \begin{bmatrix} \sum_i 2x_i^2 (y_i - \alpha x_i^2 - \beta x_i - \gamma) \\ \sum_i 2x_i (y_i - \alpha x_i^2 - \beta x_i - \gamma) \\ \sum_i 2 (y_i - \alpha x_i^2 - \beta x_i - \gamma) \end{bmatrix}$$

- Bonne ou mauvaise nouvelle ?

- **Très bonne nouvelle !** Ces équations forment un système de  $n$  équations linéaires à  $n$  inconnues

$$\nabla_{\alpha, \beta, \gamma} \log \mathcal{L} = 0 \Leftrightarrow \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \\ \gamma \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

- Résolution par facto. matricielle (LU, QR, Choleski...)
- En python :

- `numpy.linalg.solve :`

`numpy.linalg.solve(a, b)`

Solve a linear matrix equation, or system of linear scalar equations.

Computes the "exact" solution,  $x$ , of the well-determined, i.e., full rank, linear matrix equation  $ax = b$ .

**Parameters:** `a : (... , M, M) array_like`

Coefficient matrix.

`b : {... , M, }, (... , M, K)}, array_like`

Ordinate or "dependent variable" values.

**Returns:** `x : {... , M, }, (... , M, K)} ndarray`

Solution to the system  $a x = b$ . Returned shape is identical to  $b$ .

**Raises:** `LinAlgError :`


If  $a$  is singular or not square.

- `sklearn`

# Approche par minimisation du coût


## Approches probabilistes :

trouver les paramètres  $\theta^*$  qui maximisent la vraisemblance



## Approches par coût :


trouver les paramètres  $\theta^*$  qui minimisent un coût défini



# Coût des moindres carrés (1)

observations  $\Rightarrow$  couples  $(x_i, y_i) \Rightarrow$  en principe  $y_i = a + bx_i$

en pratique :  $e_i = y_i - (a + bx_i) \neq 0$



$\Rightarrow$  on cherche la droite  $y = a + bx$  dont les couples sont le plus proches

$\Rightarrow$  min de la la somme des carrés des distances (euclidiennes) verticales entre les points et la droite



# Coût des moindres carrés (2)

## Définition de la droite

trouver  $a$  et  $b$  pour lesquels on a :  $\min_{a,b} \sum_{i=1}^n e_i^2$

ou encore :  $F(a, b) = \sum_{i=1}^n [y_i - a - bx_i]^2 \implies \min_{a,b} F(a, b)$

dérivées partielles = 0 (conditions suffisantes d'optimalité) :

$$\frac{\partial F(a, b)}{\partial a} = \sum_{i=1}^n (-2)[y_i - a - bx_i] = 0$$

$$\frac{\partial F(a, b)}{\partial b} = \sum_{i=1}^n (-2)x_i[y_i - a - bx_i] = 0$$

$$\frac{\partial F(a, b)}{\partial a} = \sum_{i=1}^n (-2)[y_i - a - bx_i] = 0 \quad (1)$$

$$\frac{\partial F(a, b)}{\partial b} = \sum_{i=1}^n (-2)x_i[y_i - a - bx_i] = 0 \quad (2)$$

## Coût des moindres carrés (3)

$$\frac{\partial F(a, b)}{\partial a} = \sum_{i=1}^n (-2)[y_i - a - bx_i] = 0 \quad (1)$$

$$\frac{\partial F(a, b)}{\partial b} = \sum_{i=1}^n (-2)x_i[y_i - a - bx_i] = 0 \quad (2)$$

**Lien avec la vision probabiliste :**

$$(1) \iff a = \bar{y} - b\bar{x}$$

$$(2) \iff b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i - a \sum_{i=1}^n x_i$$

$$\text{donc, d'après (1) : } b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i - \bar{y} \sum_{i=1}^n x_i + nb \left( \sum_{i=1}^n x_i \right)^2$$

$$\implies b = \frac{\sum_i x_i (y_i - \bar{y})}{\sum_i x_i^2 - n(\sum_i x_i)^2} = \frac{\text{cov}(x, y)}{s_x^2}$$

$$\frac{\partial F(a, b)}{\partial a} = \sum_{i=1}^n (-2)[y_i - a - bx_i] = 0 \quad (1)$$

$$\frac{\partial F(a, b)}{\partial b} = \sum_{i=1}^n (-2)x_i[y_i - a - bx_i] = 0 \quad (2)$$

Résolution du système d'équations linéaires :

$$\nabla_{a,b} \text{Cost} = 0 \Leftrightarrow \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

Avec :

$$\begin{aligned} a_{11} &= n & a_{12} &= \sum_i x_i & b_1 &= \sum_i y_i \\ a_{21} &= \sum_i x_i & a_{22} &= \sum_i x_i^2, & b_2 &= \sum_i x_i y_i \end{aligned}$$

Posons  $\hat{y}_i = a + bx_i$

$s_y^2$  = variance empirique de  $Y$  :

$$\begin{aligned}s_y^2 &= \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i + e_i - \bar{y})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (e_i)^2 + 2 \frac{1}{n} \sum_{i=1}^n e_i (\hat{y}_i - \bar{y})\end{aligned}$$

# En route vers l'indicateur $R^2$

Posons  $\hat{y}_i = a + bx_i$

$s_y^2$  = variance empirique de  $Y$  :

$$\begin{aligned}s_y^2 &= \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i + e_i - \bar{y})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (e_i)^2 + 2 \frac{1}{n} \sum_{i=1}^n e_i (\hat{y}_i - \bar{y})\end{aligned}$$

$$\text{Or } \frac{1}{n} \sum_{i=1}^n e_i (\hat{y}_i - \bar{y}) = \text{cov}(e_i, \hat{y}_i) = \text{cov}(e_i, a + bx_i) = b \text{cov}(e_i, x_i) = 0$$

$$\text{Donc } s_y^2 = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (e_i)^2$$

= variance expliquée + variance résiduelle

$s_y^2$  = variance empirique de  $Y$  :


$$s_y^2 = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

= variance expliquée + variance résiduelle


$$R^2 = \frac{\sum_i (\hat{y}_i - \bar{y})^2}{\sum_i (y_i - \hat{y}_i)^2} = \frac{\text{variance expliquée}}{\text{variance résiduelle}}$$

Le modèle linéaire rend d'autant mieux compte de la liaison entre  $X$  et  $Y$  que  $R^2$  est plus proche de 1

## l'indicateur $R^2$ (2/2)



$R^2$  petit

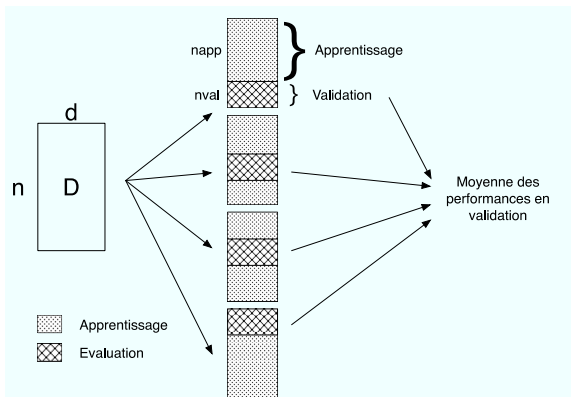


$R^2$  élevé



# Autre indicateur de qualité... très empirique

- Erreur de reconstruction moyenne en apprentissage **et en test** !
- La plupart du temps, on a une connaissance métier pour juger la qualité des modèles
- Lorsque les données manquent... validation croisée



- La plupart des données réelles sont multi-dimensionnelles

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ \vdots & & & \\ x_{N1} & x_{N2} & \cdots & x_{Nd} \end{bmatrix}, Y = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}.$$

$x_{ij}$

- $i$  représente un indice d'échantillon
- $j$  un indice de caractéristique.

Notre but : estimer  $E[Y|X_1, X_2, \dots, X_d]$

- L'hypothèse linéaire correspond à :

$$f(\mathbf{x}_i) = \sum_j x_{ij} w_j + b, \quad \mathbf{x}_i \in \mathbb{R}^d$$

- Le problème de minimisation du coût des moindres carrés :

$$\mathbf{w}^*, b^* = \arg \min_{\mathbf{w}, b} \sum_{i=1}^N (f_{\mathbf{w}, b}(\mathbf{x}_i) - y_i)^2$$

- Quand les dimensions augmentent, le modèle linéaire devient complexe

Il est possible d'écrire le problème précédent sous forme matricielle :

- plus simple à écrire + inclusion du biais

$$f(\mathbf{x}_i) = \langle \mathbf{x}_i^\dagger, \mathbf{w}^\dagger \rangle, \quad \text{avec : } \mathbf{x}_i^\dagger = [\mathbf{x}_i, 1] \text{ et } \mathbf{w}^\dagger = [\mathbf{w}, b]$$

- On considère en général  $\mathbf{w}$  comme un vecteur colonne...

$$\mathbf{w}^{\dagger*} = \arg \min_{\mathbf{w}^\dagger} (X^\dagger \mathbf{w}^\dagger - Y)^T (X^\dagger \mathbf{w}^\dagger - Y)$$

- résolution adaptée aux langages de script inaptes aux boucles

Il est possible d'écrire le problème précédent sous forme matricielle :

- plus simple à écrire + inclusion du biais

$$f(\mathbf{x}_i) = \langle \mathbf{x}_i^\dagger, \mathbf{w}^\dagger \rangle, \quad \text{avec : } \mathbf{x}_i^\dagger = [\mathbf{x}_i, 1] \text{ et } \mathbf{w}^\dagger = [\mathbf{w}, b]$$

- On considère en général  $\mathbf{w}$  comme un vecteur colonne...

$$\mathbf{w}^{\dagger*} = \arg \min_{\mathbf{w}^\dagger} (X^\dagger \mathbf{w}^\dagger - Y)^T (X^\dagger \mathbf{w}^\dagger - Y)$$

- résolution adaptée aux langages de script inaptes aux boucles
- résolution très rapide sur GPU

$$\frac{\partial C}{\partial w_j} = \sum_i 2x_{ij}(f_{\mathbf{w}}(\mathbf{x}_i) - y_i)$$

$$\nabla_{\mathbf{w}} C = \begin{bmatrix} \frac{\partial C}{\partial w_1} \\ \vdots \\ \frac{\partial C}{\partial w_d} \end{bmatrix} = 2X^T(X\mathbf{w} - Y) \in \mathbb{R}^d$$

$$\frac{\partial C}{\partial w_j} = \sum_i 2x_{ij}(f_{\mathbf{w}}(\mathbf{x}_i) - y_i)$$



$$\nabla_{\mathbf{w}} C = \begin{bmatrix} \frac{\partial C}{\partial w_1} \\ \vdots \\ \frac{\partial C}{\partial w_d} \end{bmatrix} = 2X^T(X\mathbf{w} - Y) \in \mathbb{R}^d$$

**Résolution :**

$$\nabla_{\mathbf{w}} C = 0 \Leftrightarrow X^T X \mathbf{w} = X^T Y$$

Système d'équations linéaires :  $X^T X \in \mathbb{R}^{d \times d}$ ,  $X^T Y \in \mathbb{R}^{d \times 1}$



# Passage au non linéaire



Assez trivial : il suffit d'une astuce...



# Passage au non linéaire



Assez trivial : il suffit d'une astuce...

- Concaténation :

$$X_e = [1, X, X \cdot X]$$

- Puis résolution standard :  $X_e^T X_e \mathbf{w}_e = X_e^T Y$
- Attention à l'inférence sur les nouveaux points et à l'interprétation de  $\mathbf{w}_e$

Ce cadre de formalisation est très large et généralisable...

- Données  $\mathbf{x} \in \mathbb{R}^d$ , hypothèse iid : tous les  $\mathbf{x}$  sont indépendants
- **Etiquettes**  $y$  : Classes (discrimination) , Réels (régression)
- **But** : construire une fonction  $f$  telle que  $f(\mathbf{x})$  soit une bonne approximation de  $y$
- **Critères** :
  - Coût  $C$  :

$$\arg \min_{\theta} \sum_{i=1}^N \Delta(f_{\theta}(\mathbf{x}_i), y_i)$$

- Moindres carrés :

$$C = \sum_{i=1}^N \Delta(f_{\theta}(\mathbf{x}_i), y_i) = \sum_{i=1}^N (f_{\theta}(\mathbf{x}_i) - y_i)^2$$

- Coût charnière (codage  $y = \{+1, -1\}$ )

$$C = \sum_{i=1}^N \Delta(f_{\theta}(\mathbf{x}_i), y_i) = \sum_{i=1}^N (-y_i f_{\theta}(\mathbf{x}_i))_+$$

Dans le cas des fonctions de coût exotique (cf coût logistique), il manque parfois une solution analytique

## Algorithme itératif :

- 1 Initialiser  $\mathbf{w}_0$
- 2 En boucle (avec mise à jour du gradient) :

$$\mathbf{w}^{t+1} = \mathbf{w}^t - \epsilon \nabla_{\mathbf{w}} C$$

A condition de choisir  $\epsilon$  suffisamment petit et de faire suffisamment d'itération, nous trouvons  $\mathbf{w}^*$

Le calcul de  $\nabla_{\mathbf{w}} C$  est coûteux... Il est possible de décomposer le problème :

$$C = \sum_{i=1}^N C_i, \quad C_i = (\mathbf{x}_i \mathbf{w} - y_i)^2$$

Algorithme stochastique (Cas MC : ADALINE) :

- ➊ Initialiser  $\mathbf{w}_0$
- ➋ En boucle (avec mise à jour du gradient) :
  - Tirage aléatoire d'un échantillon  $i$
  - Calcul de  $\nabla_{\mathbf{w}} C_i$  (cas MC :  $\nabla_{\mathbf{w}} C_i = 2\mathbf{x}_i^T (\mathbf{x}_i \mathbf{w} - y_i)$ )
  - MAJ :  $\mathbf{w}^{t+1} = \mathbf{w}^t - \epsilon \nabla_{\mathbf{w}} C_i$

## Perceptron

Algorithme de classification binaire des années 60 : toujours très efficace aujourd'hui

$$C = \sum_{i=1}^N (-y_i \mathbf{x}_i \mathbf{w})_+$$

Algorithme stochastique (Cas charnière : Perceptron) :

- 1 Initialiser  $\mathbf{w}_0$
- 2 En boucle (avec mise à jour du gradient) :
  - Tirage aléatoire d'un échantillon  $i$
  - Si  $y_i \mathbf{x}_i \mathbf{w} \leq 0$ 
    - Calcul de  $\nabla_{\mathbf{w}} C_i = -y_i \mathbf{x}_i^T$
    - MAJ :  $\mathbf{w}^{t+1} = \mathbf{w}^t - \epsilon \nabla_{\mathbf{w}} C_i$